oke dịch lại final proposal cho t sang TV đi

ĐỀ XUẤT DỰ ÁN 1 — HOW MUCH INTELLIGENCE CAN WE GET FOR HOW LITTLE?

Đo lường hiệu năng dự đoán của hệ thống gợi ý theo lượng lịch sử hành vi gần đây

---

1. Câu hỏi nghiên cứu và động lực

Các hệ thống gợi ý tuần tự hiện đại có thể duy trì lịch sử hành vi của người dùng gồm hàng trăm hoặc hàng nghìn tương tác. Tuy nhiên, giá trị dự đoán của việc bổ sung thêm lịch sử không nhất thiết tăng tương ứng với độ dài lịch sử. Các tương tác gần đây có thể chứa tín hiệu sở thích mạnh, trong khi các tương tác cũ hơn có thể mang thông tin trùng lặp, yếu hoặc nhiễu.

Điều này dẫn đến câu hỏi nền tảng về **hiệu quả của lịch sử hành vi**:

> **Một hệ thống gợi ý cần ít đến mức nào về lịch sử hành vi gần đây nhưng vẫn có thể duy trì phần lớn hiệu năng dự đoán đo được?**

Dự án nghiên cứu câu hỏi này trong miền **gợi ý video ngắn**, sử dụng bộ dữ liệu **KuaiRand**.

Tại mỗi thời điểm quan sát một cơ hội gợi ý, hệ thống được giả định có quyền truy cập vào:

- lịch sử hành vi đủ điều kiện của người dùng trước thời điểm đó;
- video thực tế được hiển thị cho người dùng;
- kết quả tương tác quan sát được sau lần hiển thị đó.

Thay vì đề xuất một kiến trúc gợi ý mới, dự án xem **độ dài lịch sử hành vi** như một tài nguyên thí nghiệm có thể kiểm soát.

Can thiệp chính của thí nghiệm là:

$$K \in \{0, 1, 5, 10, 20, 50, 100, \text{Full}\}$$

trong đó K biểu thị số lượng tối đa các tương tác hành vi đủ điều kiện gần đây nhất được cung cấp cho mô hình trước một thời điểm quyết định.

Nguyên tắc thực nghiệm trung tâm là:

$$\text{Giảm lịch sử hành vi}$$

$$\downarrow$$

$$\text{Giữ nguyên môi trường thực nghiệm}$$

$$\downarrow$$

$$\text{Đo lượng hiệu năng dự đoán còn lại}$$

Do đó, câu hỏi nghiên cứu chính là:

> **Một hệ thống gợi ý có thể sử dụng ít đến mức nào về lịch sử hành vi gần đây mà vẫn giữ được phần lớn hiệu năng dự đoán đo được?**

Thuật ngữ **"intelligence"** trong tên dự án chỉ mang tính định hướng và truyền đạt ý tưởng. Về mặt khoa học, dự án đo lường **hiệu năng dự đoán của hệ thống gợi ý trong một quy trình đánh giá offline được xác định rõ**, chứ không đo "trí thông minh" nói chung và cũng không đo một đại lượng thông tin theo lý thuyết thông tin.

---

2. Mục tiêu nghiên cứu

Dự án có năm mục tiêu chính.

Mục tiêu 1 — Định lượng giá trị của lịch sử hành vi gần đây

Đo lường hiệu năng dự đoán theo ngân sách lịch sử hành vi:

$$K \to \mathrm{AUC}(K)$$

Mục tiêu 2 — Đặc trưng hóa lợi ích biên của việc bổ sung lịch sử

Đo mức thay đổi hiệu năng khi bổ sung thêm lịch sử:

$$\Delta\mathrm{AUC}(K_i, K_j) = \mathrm{AUC}(K_j) - \mathrm{AUC}(K_i)$$

Dự án **không giả định** rằng các chênh lệch này luôn dương.

Mục tiêu 3 — Đo mức duy trì hiệu năng tương đối

Xác định bao nhiêu phần hiệu năng dự đoán vượt trên mức ngẫu nhiên của điều kiện Full được duy trì ở mỗi ngân sách lịch sử hữu hạn.

Mục tiêu 4 — Xác định điểm bão hòa thực tiễn

Định nghĩa điểm bão hòa mô tả là:

$$K^* = \min\{K : \text{Retention}(K) \geq 0.95\}$$

Đây là ngân sách lịch sử nhỏ nhất trong các mức K được kiểm nghiệm đạt ít nhất 95% hiệu năng dự đoán vượt trên mức ngẫu nhiên của điều kiện Full.

Đây chỉ là một đại lượng mô tả trong môi trường thực nghiệm, **không phải độ dài lịch sử tối ưu mang tính phổ quát**.

Mục tiêu 5 — Kiểm tra độ bền của kết quả

Xác định liệu quan hệ giữa lịch sử và hiệu năng có còn tương đối ổn định khi thay đổi trước các yếu tố đã được quy định:

- cửa sổ lịch sử;
- cơ chế tổng hợp lịch sử;
- giai đoạn thời gian;
- mức độ hoạt động của người dùng;
- biến mục tiêu;
- kiến trúc tuần tự nhẹ.

Nghiên cứu chính vẫn tập trung vào tác động của **độ dài lịch sử hành vi**, thay vì tối ưu kiến trúc.

---

3. Phạm vi khoa học

Dự án đánh giá **khả năng phân biệt dự đoán trên các sự kiện hiển thị đã quan sát được**.

Với một sự kiện hiển thị quan sát được, mô hình ước lượng:

$$P(Y = 1 \mid H_t^{(K)}, V)$$

KuaiRand không cung cấp kết quả quan sát được cho mọi video ứng viên có thể tồn tại tại mọi thời điểm quyết định trong quá khứ. Vì vậy, dự án **không cố gắng tái dựng đầy đủ các slate gợi ý lịch sử** và không ước lượng kết quả cho toàn bộ các video ứng viên không quan sát được.

Do đó, nhiệm vụ chính là:

> **Phân biệt dự đoán trên các lần hiển thị quan sát được**

thay vì:

> **Đánh giá đầy đủ một chính sách gợi ý offline.**

ROC-AUC vì vậy được diễn giải là **chất lượng xếp hạng dự đoán giữa các lần hiển thị quan sát được trong tập đánh giá**.

ROC-AUC **không được diễn giải** là:

- chất lượng hoàn chỉnh của chính sách gợi ý;
- chất lượng xếp hạng phản thực;
- hiệu ứng nhân quả;
- thành công của hệ thống gợi ý trong production.

Các quan sát từ **random intervention** được sử dụng vì chúng cung cấp một quần thể đánh giá có thành phần can thiệp ngẫu nhiên. Tuy nhiên, dự án **không tuyên bố** rằng random intervention loại bỏ hoàn toàn mọi nguồn sai lệch.

---

4. Bộ dữ liệu

Bộ dữ liệu chính là **KuaiRand**, một bộ dữ liệu gợi ý tuần tự thực tế được thu thập từ Kuaishou.

KuaiRand chứa:

- các tương tác người dùng–video theo thứ tự thời gian;
- thông tin phía người dùng;
- thông tin video/item;
- timestamp;
- nhiều tín hiệu phản hồi hành vi;
- các tương tác được hiển thị thông qua cơ chế can thiệp ngẫu nhiên.

Dự án sử dụng hai giai đoạn tính toán.

4.1. Bộ dữ liệu phát triển — KuaiRand-1K

KuaiRand-1K được sử dụng cho:

- phân tích dữ liệu khám phá;
- tái dựng dữ liệu;
- kiểm tra tính hợp lệ theo thời gian;
- kiểm tra leakage;
- phân tích cửa sổ lịch sử;
- đánh giá chi phí tính toán;
- triển khai mô hình;

- kiểm thử bootstrap;
- debugging;
- lựa chọn protocol.

Đây là môi trường phát triển và **không được xem là kết quả đánh giá xác nhận cuối cùng**.

4.2. Bộ dữ liệu cuối — KuaiRand-27K

KuaiRand-27K được sử dụng cho thí nghiệm cuối cùng sau khi protocol đã được khóa.

Sau khi protocol được khóa, kết quả trên tập cuối **không được sử dụng để thay đổi protocol chính**.

Các thống kê chính xác của dataset trong báo cáo cuối sẽ được tính trực tiếp từ đúng phiên bản/file dataset được sử dụng trong implementation và được lưu trong cấu hình tái lập, thay vì phụ thuộc vào các con số hard-code từ nguồn bên ngoài.

Thí nghiệm cuối sẽ ghi nhận:

- phiên bản dataset chính xác;
- các file đầu vào chính xác;
- số người dùng;
- số video/item;
- số tương tác;
- số quan sát intervention;
- khoảng thời gian;
- phiên bản preprocessing.

---

5. Tổ chức dữ liệu theo thời gian

Dataset được xử lý theo thứ tự thời gian.

Về mặt khái niệm:

$$\text{Giai đoạn lịch sử} \rightarrow \text{Training} \rightarrow \text{Validation} \rightarrow \text{Giai đoạn thực nghiệm} \rightarrow \text{Đán}$$

Các mốc timestamp chính xác được xác định từ các file dataset thực tế và lưu trong experiment configuration.

Không được sử dụng random train-test split trên dữ liệu thời gian.

Giai đoạn thực nghiệm phải xảy ra sau giai đoạn training.

---

6. Chia Training và Validation

Giai đoạn lịch sử được chia theo thứ tự thời gian thành training và validation.

Training xảy ra trước validation.

Validation có thể được sử dụng cho:

- early stopping;
- lựa chọn hyperparameter trong không gian tìm kiếm đã định trước;
- lựa chọn mô hình giữa các cấu hình đã định trước.

Dữ liệu của giai đoạn thực nghiệm cuối **không bao giờ được sử dụng** cho:

- tuning hyperparameter;
- lựa chọn kiến trúc;
- lựa chọn history window;
- lựa chọn maximum sequence length;
- lựa chọn feature;
- lựa chọn threshold.

---

7. Quần thể đánh giá

Quần thể đánh giá chính gồm các **sự kiện hiển thị random-intervention đủ điều kiện** trong giai đoạn thực nghiệm đã được xác định trước.

Mỗi sự kiện được xem là:

> **một lần hiển thị quan sát được, với một candidate quan sát được và một kết quả tương tác quan sát được.**

Dự án không giả định rằng:

- mọi candidate có thể đã được hiển thị đều được quan sát;
- mọi video ứng viên đều được quan sát;
- toàn bộ recommendation slate có thể tái dựng;
- mọi kết quả phản thực đều có sẵn;
- random intervention cung cấp đầy đủ causal identification.

Do đó, các kết luận được giới hạn trong **quy trình đánh giá dựa trên các lần hiển thị intervention quan sát được**.

---

8. Đơn vị đánh giá và thời điểm quyết định

Một đơn vị đánh giá được định nghĩa là:

$$d_j = (u_j, t_j, v_j, y_j)$$

trong đó:

- u_j: người dùng;
- t_j: timestamp của lần hiển thị/quyết định;
- v_j: video thực tế được hiển thị tại timestamp đó;
- y_j: biến mục tiêu quan sát được.

Do đó:

> **Một đơn vị đánh giá = một sự kiện hiển thị intervention quan sát được.**

Nó **không phải**:

- một người dùng;
- một session;
- một recommendation slate;
- một candidate giả định.

Tập đánh giá cuối là:

$$D_{\text{eval}} = \{d_1, d_2, \ldots, d_N\}$$

Cùng một tập sự kiện được sử dụng cho mọi ngân sách lịch sử:

$$D_{\text{eval}}^{(0)} = D_{\text{eval}}^{(1)} = \cdots = D_{\text{eval}}^{(100)} = D_{\text{eval}}^{(\text{Full})}$$

Việc có đủ lịch sử hay không **không quyết định** một sự kiện có thuộc tập đánh giá hay không.

---

9. Ngữ nghĩa của Candidate

Dự án phân biệt rõ giữa **candidate quan sát được** và **tập candidate đầy đủ**.

Candidate quan sát được

Đối với sự kiện d_j, candidate quan sát được là:

$$v_j$$

tức video thực tế được hiển thị cho người dùng.

Tập candidate đầy đủ

Tập candidate đầy đủ sẽ là tập tất cả các video mà hệ thống gợi ý lịch sử có thể đã cân nhắc tại thời điểm t_j.

Tập này **không thể quan sát đầy đủ từ KuaiRand**.

Do đó, dự án không tuyên bố tái dựng:

$$C_t = \{\text{tất cả candidate có thể có tại } t\}$$

Thay vào đó, mô hình tính:

$$\text{score}_j^{(K)} = f_K(H_{t_j}^{(K)}, v_j)$$

trên candidate quan sát được v_j.

Đánh giá chính hỏi liệu mô hình có thể phân biệt tốt giữa các kết quả dương và âm quan sát được hay không.

Vì vậy, dự án **không đưa ra kết luận về khả năng xếp hạng toàn bộ video có thể tồn tại**.

---

10. Định nghĩa một sự kiện lịch sử hành vi đủ điều kiện

Một tương tác được coi là **eligible history event** khi và chỉ khi thỏa mãn tất cả điều kiện:

1. thuộc stream tương tác được định nghĩa trước cho lịch sử;
2. có user ID hợp lệ;
3. có timestamp hợp lệ;
4. timestamp nằm trước timestamp quyết định;
5. các feature bắt buộc thỏa mãn feature-availability contract.

Tính đủ điều kiện được xác định **độc lập với** K.

Các bảng/file nguồn chính xác tạo thành eligible-history stream được khóa trong protocol và lưu trong configuration.

Một sự kiện không tự động trở thành history chỉ vì nó tồn tại ở đâu đó trong dataset.

Điều này ngăn các implementation khác nhau âm thầm định nghĩa “history” theo những cách khác nhau.

---

11. Sự kiện trong giai đoạn thực nghiệm có thể trở thành history

Một sự kiện lịch sử xảy ra trong giai đoạn thực nghiệm có thể đóng góp vào lịch sử của một sự kiện đánh giá xảy ra sau đó nếu thỏa mãn các điều kiện về eligibility.

Ví dụ, nếu:

$$t_a < t_b$$

thì e_a có thể được đưa vào:

$$H_{t_b}^{(K)}$$

nếu e_a là một history event đủ điều kiện.

Điều này phản ánh lượng thông tin thực tế mà hệ thống có thể quan sát tại thời điểm t_b.

Tuy nhiên, những sự kiện mới này **không được cập nhật tham số mô hình**.

Do đó:

$$e_a \to H_{t_b}^{(K)}$$

được phép, nhưng:

$$e_a \to \theta_K$$

bị cấm.

Tham số đã học được giữ nguyên trong toàn bộ giai đoạn thực nghiệm.

---

12. Định nghĩa lịch sử hành vi

Với mỗi timestamp quyết định t, định nghĩa lịch sử đủ điều kiện trong cửa sổ thời gian W:

$$H_t^W = \{e_i : t - W \leq t_i < t\}$$

Điều kiện nghiêm ngặt:

$$t_i < t$$

là bắt buộc.

Không có sự kiện xảy ra tại hoặc sau timestamp quyết định được phép đi vào history.

Với ngân sách lịch sử hữu hạn K:

$$H_t^{(K)} = \text{Last}_{\min(K, L_{\max})}\left(H_t^W\right)$$

Các ngân sách chính là:

$$K \in \{0, 1, 5, 10, 20, 50, 100, \text{Full}\}$$

Với $K = 0$:

$$H_t^{(0)} = \varnothing$$

---

13. Định nghĩa Full History

"Full history" **không có nghĩa** là toàn bộ timeline vô hạn của người dùng.

Trước tiên, xác định cửa sổ thời gian:

$$H_t^W = \{e_i : t - W \leq t_i < t\}$$

Sau đó áp dụng giới hạn độ dài chuỗi $L_{\max}$.

Điều kiện Full là:

$$H_t^{(\text{Full})} = \text{Last}_{L_{\max}}\left(H_t^W\right)$$

Do đó:

> **Full = toàn bộ các tương tác đủ điều kiện gần đây nằm trong cửa sổ thời gian W, nhưng không vượt quá độ dài chuỗi $L_{\max}$.**

Protocol chính yêu cầu:

$$L_{\max} \geq 100$$

Điều này bảo đảm tất cả các mức lịch sử hữu hạn được thử nghiệm đều có thể được biểu diễn trong điều kiện Full.

Với mọi K hữu hạn:

$$H_t^{(K)} \subseteq H_t^{(\text{Full})}$$

Giá trị cuối cùng của W và $L_{\max}$ được lựa chọn trong giai đoạn phát triển và khóa trước đánh giá cuối.

---

14. Lựa chọn W và $L_{\max}$

W và $L_{\max}$ được lựa chọn **chỉ bằng dữ liệu phát triển**.

Các cửa sổ thời gian ứng viên có thể bao gồm:

$$W \in \{1 \text{ ngày}, 3 \text{ ngày}, 7 \text{ ngày}, 14 \text{ ngày}\}$$

Với mỗi W, phân phối:

$$N_t(W) = |H_t^W|$$

được đo lường.

Báo cáo bao gồm:

- median;
- P75;
- P90;
- P95;
- P99;
- maximum.

Sau đó $L_{\max}$ được lựa chọn nhằm đáp ứng:

1. cung cấp ngữ cảnh hành vi gần đây có ý nghĩa;
2. khả thi về mặt tính toán;
3. giới hạn độ dài chuỗi;
4. bao phủ đủ các sự kiện lịch sử đủ điều kiện.

Quy trình:

$$\text{Development EDA} \rightarrow \text{chọn } W^*, L_{\max}^* \rightarrow \text{khóa protocol} \rightarrow \text{thí nghiệm KuaiRa}$$

Kết quả trên tập test cuối **không được dùng** để thay đổi W^* hoặc $L_{\max}^*$.

---

15. Không sessionization trong thí nghiệm chính

Thí nghiệm chính **không sử dụng sessionization**.

History cốt lõi chỉ dựa trên điều kiện thời gian:

$$H_t^{(K)} = \text{Last}_K\left(\{e_i : t - W \le t_i < t\}\right)$$

Không sử dụng ngưỡng session-gap tùy ý như 15, 30 hoặc 60 phút trong thí nghiệm chính.

Session-aware history chỉ được sử dụng trong sensitivity analysis.

Điều này đảm bảo biến chính được thao tác là:

ngân sách lịch sử hành vi K.

---

16. Nguyên tắc ngân sách thông tin

K biểu thị số lượng tối đa các tương tác hành vi quan sát được gần đây được cung cấp cho mô hình.

Do đó, thuật ngữ được sử dụng là:

> **Ngân sách lịch sử hành vi — Behavioral History Budget.**

Không xem K là một phép đo tuyệt đối của "lượng thông tin".

Cụ thể:

$$K \neq \text{information content}$$

Hai history có cùng số lượng sự kiện hoàn toàn có thể chứa lượng tín hiệu dự đoán khác nhau.

Dự án không tuyên bố đo:

- entropy;
- mutual information;
- phần trăm thông tin của người dùng;
- information-theoretic sufficiency.

Phát biểu khoa học chính xác là:

> **Hiệu năng dự đoán thay đổi như thế nào khi số lượng các tương tác hành vi gần đây được cung cấp cho mô hình bị giới hạn?**

---

17. Ràng buộc nghiêm ngặt về ngân sách thông tin

Mọi feature phụ thuộc vào hành vi được sử dụng tại timestamp t phải được tính toán hoàn toàn từ thông tin có sẵn trước t.

Về hình thức:

$$\text{InformationUsed}(t) \subseteq \text{InformationAvailableBefore}(t)$$

Mô hình có thể sử dụng:

- $H_t^{(K)}$;
- thông tin candidate hợp lệ tại t;
- thông tin tĩnh thỏa mãn feature-availability contract.

Mô hình không được sử dụng:

- tương tác tương lai;
- feedback tương lai;
- popularity tương lai;
- user representation tương lai;
- aggregate statistic tương lai;
- user embedding được học từ hành vi tương lai;
- candidate feature được tính từ quan sát sau thời điểm quyết định.

Invariant này áp dụng cho cả thông tin phía user và candidate.

---

18. Feature Availability Contract

Mọi feature được phân thành ba nhóm.

Loại A — Static Features

Các feature có thể tồn tại mà không cần thông tin hành vi tương lai.

Ví dụ:

- thời lượng video;
- categorical metadata tĩnh;
- các thuộc tính item cố định khác.

Loại B — Historical Dynamic Features

Các feature có thể thay đổi theo thời gian nhưng có thể tái dựng từ thông tin có sẵn trước t.

Ví dụ:

$$\text{Popularity}(v, t)$$

chỉ hợp lệ nếu được tính từ các tương tác thỏa mãn ràng buộc thời gian.

Loại C — Future-Dependent Features

Bất kỳ feature nào yêu cầu thông tin từ:

$$t_i \geq t$$

đều bị cấm.

Phân loại feature được tạo **trước đánh giá cuối** và lưu trong experiment configuration.

---

19. Biểu diễn Candidate chính

Để giảm sự mơ hồ và rủi ro leakage, thí nghiệm chính sử dụng biểu diễn candidate chỉ dựa trên các feature tĩnh hoặc an toàn trước thời điểm quyết định.

Candidate representation chính có thể bao gồm:

- video identity representation được xây dựng theo protocol được phê duyệt;
- thời lượng video;
- categorical information tĩnh;
- các thuộc tính video tĩnh khác thỏa mãn feature-availability contract.

Các dynamic candidate statistics **không bắt buộc** trong thí nghiệm chính.

Đặc biệt, popularity không thuộc candidate representation cốt lõi trừ khi được đưa vào feature configuration đã khóa.

Nếu nghiên cứu dynamic candidate features, chúng chỉ được đưa vào sensitivity analysis đã định trước và phải được tái dựng nghiêm ngặt từ thông tin có trước timestamp quyết định.

Điều này ngăn candidate-side temporal statistics trở thành một biến can thiệp thứ hai không được kiểm soát.

---

20. User Identity

Raw user ID **không được sử dụng như một user representation có thể học** trong thí nghiệm history-budget chính.

Một user embedding được train trên toàn bộ timeline có thể ngầm mã hóa thông tin nằm ngoài ngân sách lịch sử.

Ví dụ, ở $K = 1$, một embedding được train từ toàn bộ timeline có thể chứa thông tin từ hàng trăm tương tác mà điều kiện $K = 1$ lẽ ra phải loại bỏ.

Do đó, user state được xây dựng từ history được phép:

$$\mathrm{UserState}_t^{(K)} = g(H_t^{(K)})$$

Không được xây dựng theo kiểu:

$$\text{UserState}_t = \text{Embedding}(\text{UserID})$$

với embedding được train từ toàn bộ timeline.

Điều này bảo toàn ràng buộc về lượng thông tin hành vi.

---

21. Biểu diễn sự kiện

Mỗi history event được biểu diễn chỉ bằng thông tin được phép theo feature-availability contract.

Với event e_i:

$$x_i = \text{EventEncoder}(e_i)$$

Biểu diễn có thể bao gồm:

- representation của video đã tương tác;
- các feature video được phép;
- feedback quan sát được theo protocol;
- thông tin thời gian.

Thời gian tương đối có thể biểu diễn bằng:

$$\Delta t_i = t - t_i$$

Điều này cho phép mô hình phân biệt các tương tác gần đây và cũ hơn.

Không được gắn future feedback vào event nếu feedback đó chưa có sẵn tại thời điểm mà event được sử dụng.

---

22. Kiến trúc mô hình chính

Mô hình chính được thiết kế nhẹ.

Mục tiêu là cô lập tác động của history budget thay vì tối ưu kiến trúc.

Mô hình gồm:

$$\text{Recent History} \rightarrow \text{Event Encoder} \rightarrow \text{Shared History Aggregation} \rightarrow \text{User Sta}$$

kết hợp với:

$$\text{Candidate Video Representation}$$

sau đó:

$$\text{User State} + \text{Candidate Representation} \rightarrow \text{MLP} \rightarrow \hat{P}(Y = 1)$$

Về hình thức:

$$\hat{p} = P(Y = 1 \mid H_t^{(K)}, V)$$

---

23. Tổng hợp lịch sử

Cơ chế aggregation chính là **mean pooling**:

$$h_t^{(K)} = \frac{1}{|H_t^{(K)}|} \sum_{e_i \in H_t^{(K)}} x_i$$

Thông tin thời gian được tích hợp trong event representation.

Với $K = 0$:

$$h_t^{(0)} = \mathbf{0}$$

Điều kiện $K = 0$ vẫn sử dụng **cùng kiến trúc downstream** như các điều kiện khác nhưng nhận history representation bằng vector zero.

Không tạo một kiến trúc riêng cho $K = 0$.

Recency-weighted aggregation được dành cho sensitivity analysis.

Các kiến trúc phức tạp hơn như GRU hoặc Transformer không bắt buộc trong thí nghiệm chính.

---

24. Kiểm soát năng lực mô hình

Tất cả các mô hình history-budget chính sử dụng giống nhau:

- event encoder;
- embedding dimensions;
- hidden dimensions;
- aggregation mechanism;
- prediction head;
- parameterization;
- optimizer;
- learning-rate schedule;

- batch size;
- loss;
- early-stopping rule;
- training procedure.

Do đó:

$$\text{Model Capacity} = \text{Constant}$$

trong khi:

$$\text{History Budget} = \text{Variable}$$

Số lượng parameter của các điều kiện K hữu hạn là giống nhau.

Chi phí tính toán được phép thay đổi theo K, vì độ dài history chính là tài nguyên thực nghiệm.

Compute efficiency vì vậy được báo cáo riêng và **không phải outcome khoa học chính**.

---

25. Training Protocol chính

Một mô hình riêng được train cho mỗi history budget:

$$M_K = \text{Train}(D_{\text{train}}, H^{(K)})$$

Do đó:

$$M_0, M_1, M_5, M_{10}, M_{20}, M_{50}, M_{100}, M_{\text{Full}}$$

được train độc lập bằng cùng specification và training protocol.

Điều này cần thiết vì câu hỏi chính là:

> **Một mô hình được huấn luyện và suy luận dưới một ngân sách lịch sử cụ thể có thể đạt hiệu năng đến đâu?**

Train một Full-history model rồi chỉ cắt history khi inference sẽ trả lời một câu hỏi khác.

---

26. Frozen-Model Protocol

Sau khi training và model selection:

$$\theta_K^{\text{trained}}$$

được đóng băng.

Không cập nhật parameter trong giai đoạn thực nghiệm.

Các quan sát mới có thể trở thành pre-decision history của các evaluation event xảy ra sau đó nếu chúng thỏa mãn eligibility.

Tuy nhiên, chúng không bao giờ thay đổi:

$$\theta_K$$

Do đó:

$$\text{Training History} \rightarrow \theta_K \rightarrow \text{Freeze} \rightarrow \text{Experimental Inference}$$

---

27. Thí nghiệm phụ: Full-Trained Truncation

Một thí nghiệm robustness phụ có thể train một Full-history model:

$$M_{\text{Full}}$$

sau đó đánh giá bằng các history bị cắt:

$$H_t^{(K)}$$

Thí nghiệm này trả lời một câu hỏi khác:

> **Một mô hình được train với Full history có bền vững đến đâu khi history bị thiếu ở thời điểm inference?**

Thí nghiệm này **không thuộc kết quả history-budget chính**.

Kết luận chính dựa trên training theo đúng ngân sách K.

---

28. Biến mục tiêu chính

Biến mục tiêu chính là:

$$Y = \text{long_view}$$

Nhãn long-view có sẵn trong dataset được sử dụng trực tiếp.

Không đưa thêm một threshold watch-ratio chủ quan.

Cụ thể:

$$Y = \begin{cases} 1, & \text{nếu long_view} = 1 \\ 0, & \text{nếu long_view} = 0 \end{cases}$$

Các feedback khác như click hoặc like có thể được đánh giá như outcome phụ.

Câu hỏi nghiên cứu và metric chính vẫn dựa trên long-view.

---

29. Baseline

Có ba baseline/condition chính.

Baseline 1 — Popularity

Một heuristic popularity không cá nhân hóa, được tính chỉ bằng thông tin được phép theo temporal protocol.

Popularity baseline chính được tính từ dữ liệu interaction trong training period và sau đó được freeze trong giai đoạn đánh giá.

Baseline này trả lời:

> **Không sử dụng mô hình hóa hành vi cá nhân, có thể đạt được bao nhiêu khả năng phân biệt dự đoán?**

Baseline 2 — Video-only learned model

Mô hình không nhận history:

$$P(Y = 1 \mid V)$$

Đây chính là điều kiện $K = 0$.

Baseline 3 — Full-history reference

Cùng kiến trúc nhận:

$$H_t^{(\text{Full})}$$

Đây là điều kiện tham chiếu cho history-efficiency curve.

Nó không được coi là:

- oracle;
- hiệu năng tối đa có thể đạt;
- production recommender;
- complete behavioral knowledge.

30. History-Only Diagnostic

Một mô hình phụ nhận history nhưng không nhận candidate representation:

$$P(Y = 1 \mid H_t^{(K)})$$

Mục tiêu là tách biệt:

- tín hiệu từ candidate video;
- tín hiệu từ behavioral history;
- tín hiệu kết hợp.

Mô hình **History + Video** vẫn là thí nghiệm chính.

---

31. Các điều kiện thực nghiệm chính

$$K \in \{0, 1, 5, 10, 20, 50, 100, \text{Full}\}$$

Với mọi điều kiện:

- dataset giống nhau;
- evaluation events giống nhau;
- observed candidates giống nhau;
- target giống nhau;
- candidate representation giống nhau;
- architecture giống nhau;
- parameterization giống nhau;
- training protocol giống nhau;
- validation protocol giống nhau;
- model được freeze trước final evaluation.

Chỉ có lượng behavioral history được phép sử dụng là thay đổi.

---

32. Quy tắc khi thiếu history

Tập đánh giá cố định **không bao giờ được lọc** dựa trên việc có đủ history hay không.

Với $K > 0$, nếu evaluation event có ít hơn K history events đủ điều kiện, mô hình nhận tất cả các event có sẵn.

Do đó:

$$H_t^{(K)} = \text{Last}_{\min(K, |H_t^W|)}(H_t^W)$$

Không loại evaluation event chỉ vì:

$$|H_t^W| < K$$

Nếu:

$$H_t^W = \varnothing$$

thì:

$$h_t^{(K)} = \mathbf{0}$$

kèm theo một history-availability mask rõ ràng:

$$m_t = 0$$

Nếu tồn tại ít nhất một history event:

$$m_t = 1$$

Cùng một quy tắc được áp dụng cho mọi K.

Do đó:

$$D_{\text{eval}}^{(K)} = D_{\text{eval}}$$

với mọi K.

---

33. Tập đánh giá cố định

Trước khi scoring model, các evaluation events đủ điều kiện được xác định và freeze:

$$D_{\text{eval}} = \{(u_j, t_j, v_j, y_j)\}$$

Cùng các dòng dữ liệu được đánh giá cho:

$$K = 0, 1, 5, 10, 20, 50, 100, \text{Full}$$

Do đó:

$$K = \text{thay đổi}$$

nhưng:

$$D_{\text{eval}} = \text{không đổi}$$

Candidate không đổi:

$$v_j^{(K)} = v_j$$

Target không đổi:

$$y_j^{(K)} = y_j$$

Biến thực nghiệm duy nhất là lượng behavioral history được cung cấp.

---

34. Pipeline thực nghiệm theo thời gian

Pipeline hoàn chỉnh:

$$\text{KuaiRand}$$

$$\downarrow$$

$$\text{Data Ingestion}$$

$$\downarrow$$

$$\text{Chronological Ordering}$$

Sau đó chia thành:

$$\text{Historical Period} \qquad \text{Experimental Period}$$

Historical period:

$$\downarrow$$

$$\text{Train / Validation}$$

Experimental period:

$$\downarrow$$

$$\text{Random-Intervention Events}$$

Tiếp theo:

$$\text{Train } M_K \rightarrow \text{Freeze } \theta_K$$

đồng thời:

$$\text{Freeze } D_{\text{eval}} \rightarrow \text{Reconstruct Pre-Decision History}$$

$$\downarrow$$

$$\text{Apply History Budget}$$

$$\downarrow$$

$$K \in \{0, 1, 5, 10, 20, 50, 100, \text{Full}\}$$

$$\downarrow$$

$$\text{Frozen Inference}$$

$$\downarrow$$

$$\text{AUC}, \text{PR-AUC}$$

$$\downarrow$$

$$\text{User-Level Bootstrap}$$

$$\downarrow$$

$$\text{Retention}/\Delta\text{AUC}/CI$$

$$\downarrow$$

$$\text{Saturation Analysis}$$

---

35. Ngăn chặn Leakage

Leakage prevention là một invariant cấp cao.

Với mọi evaluation event tại t:

$$\max(t_i : e_i \in H_t^{(K)}) < t$$

Không có event tại hoặc sau t được phép đi vào history.

Mô hình không được sử dụng:

- future interactions;
- future feedback;
- future item popularity;
- future user representations;
- future aggregate statistics;
- user embeddings được train bằng future behavior;
- future candidate information.

Mọi dynamic feature phải được tái dựng bằng thông tin có sẵn trước timestamp quyết định tương ứng.

---

36. Các invariant kiểm tra tính đúng đắn

Implementation phải kiểm thử trực tiếp:

Temporal validity

$$\max(t_i : e_i \in H_t^{(K)}) < t$$

History nesting

Nếu:

$$K_1 < K_2$$

thì:

$$H_t^{(K_1)} \subseteq H_t^{(K_2)}$$

Full nesting

Với mọi K hữu hạn:

$$H_t^{(K)} \subseteq H_t^{(\text{Full})}$$

Fixed evaluation set

$$D_{\text{eval}}^{(K_1)} = D_{\text{eval}}^{(K_2)}$$

Fixed candidates

$$v_j^{(K_1)} = v_j^{(K_2)}$$

Fixed labels

$$y_j^{(K_1)} = y_j^{(K_2)}$$

Constant parameter count

$$\text{Params}(M_{K_1}) = \text{Params}(M_{K_2})$$

Frozen inference

$$\theta_K$$

không thay đổi trong toàn bộ quá trình đánh giá.

No future-dependent features

Mọi feature tại t phải thỏa:

$$\text{feature}(t) \subseteq \text{information available before}(t)$$

Các invariant này được coi là **software correctness tests**, không chỉ là tài liệu mô tả.

---

37. Metric chính

Metric chính là:

$$\text{ROC-AUC}$$

Với mỗi K:

$$\text{AUC}(K)$$

AUC đo khả năng mô hình gán prediction score cao hơn cho các observed outcomes dương so với các observed outcomes âm.

Cách diễn giải là:

> **Chất lượng xếp hạng dự đoán trong evaluation protocol dựa trên các intervention exposures quan sát được.**

Không diễn giải AUC là chất lượng hoàn chỉnh của recommendation policy.

---

38. Các metric phụ

Các metric phụ bao gồm:

- PR-AUC;
- observed positive rate;
- chênh lệch AUC tuyệt đối;
- relative predictive retention;
- bootstrap confidence interval;
- saturation point;
- inference cost;
- sequence-length statistics.

Kết luận khoa học chính vẫn dựa trên đường cong:

$$K \to \text{AUC}(K)$$

---

39. Relative Retained Predictive Performance

Metric chuẩn hóa chính:

$$\text{Retention}(K) = \frac{\text{AUC}(K) - 0.5}{\text{AUC}(\text{Full}) - 0.5}$$

Trong đó 0.5 đại diện cho random ranking đối với ROC-AUC.

Metric này đo tỷ lệ **hiệu năng dự đoán vượt trên mức ngẫu nhiên của điều kiện Full** được duy trì tại ngân sách K.

Khi mẫu số hợp lệ:

$$\text{Retention}(\text{Full}) = 1$$

Metric được gọi chính xác là:

> **Relative Retained Predictive Performance**

Không gọi là:

- information retention;
- intelligence retention;
- phần trăm thông tin người dùng được giữ lại.

Ví dụ, nếu:

$$\text{Retention}(10) = 0.95$$

thì cách diễn giải hợp lệ là:

> Trong môi trường thực nghiệm KuaiRand được định nghĩa trước, điều kiện $K = 10$ đạt khoảng 95% hiệu năng dự đoán vượt trên mức ngẫu nhiên đo được của điều kiện Full.

Điều này **không có nghĩa** 10 tương tác chứa 95% thông tin của người dùng.

---

40. Kiểm tra tính ổn định của Retention

Retention trở nên không ổn định khi:

$$\text{AUC}(\text{Full}) \approx 0.5$$

Do đó, một quy tắc ổn định mẫu số được xác định trước.

Nếu Full-history AUC quá gần random ranking theo tiêu chí đã khóa, retention chuẩn hóa không được sử dụng cho diễn giải chính.

Thay vào đó báo cáo:

$$\mathrm{AUC}(K)$$

và:

$$\Delta\mathrm{AUC}(K, \mathrm{Full}) = \mathrm{AUC}(K) - \mathrm{AUC}(\mathrm{Full})$$

Ngưỡng ổn định chính xác được khóa trước final evaluation.

---

41. Retention có thể vượt 100%

Vì mỗi mô hình finite-K được train độc lập, biến động lấy mẫu và biến động optimization có thể dẫn tới:

$$\mathrm{AUC}(K) > \mathrm{AUC}(\mathrm{Full})$$

Do đó:

$$\mathrm{Retention}(K) > 1$$

là hoàn toàn có thể về mặt toán học.

Điều này không nhất thiết là lỗi metric.

Retention là phép so sánh chuẩn hóa với Full reference quan sát được, không phải đại lượng bị ràng buộc trong $[0, 1]$.

Do đó, báo cáo cuối **không tự động cắt retention ở 100%**.

---

42. Điểm bão hòa lịch sử

Điểm bão hòa mô tả:

$$K^* = \min\{K : \mathrm{Retention}(K) \geq 0.95\}$$

Đây là ngân sách hữu hạn nhỏ nhất trong các mức K được kiểm nghiệm đạt ngưỡng 95%.

Một phiên bản bảo thủ hơn:

$$K^*_{\mathrm{LCB}} = \min\{K : \mathrm{LCB}_{95\%}(\mathrm{Retention}(K)) \geq 0.95\}$$

Do đó:

- K^*: saturation mô tả;
- K^*_{LCB}: saturation bảo thủ có xét uncertainty.

Nếu không có mức K nào thỏa mãn:

> **Không có ngân sách lịch sử nào trong các mức được kiểm nghiệm đạt ngưỡng retention 95% đã định trước.**

Không nội suy giữa các giá trị K chưa được kiểm nghiệm để xác định K^* chính.

---

43. Bất định thống kê

Các quan sát từ cùng một người dùng không được giả định là độc lập thống kê.

Một user có thể đóng góp nhiều evaluation events.

Do đó, phương pháp uncertainty chính là:

> **User-level clustered bootstrap**

Mỗi bootstrap replicate:

1. lấy mẫu người dùng có hoàn lại;
2. đưa toàn bộ evaluation observations của những user được chọn vào mẫu;
3. tính AUC cho mọi K;
4. tính paired AUC differences;
5. tính retention;
6. tùy chọn tính K^*.

Cùng một tập user được resample cho tất cả K trong một bootstrap replicate.

Điều này bảo toàn cấu trúc paired của thí nghiệm.

---

44. Protocol tính Bootstrap

Trong development:

$$B = 100$$

bootstrap replicates được sử dụng để kiểm thử implementation và debugging.

Trong final experiment, mục tiêu là:

$$B = 500$$

Nếu chi phí tính toán khiến $B = 500$ không khả thi, fallback được định trước là:

$$B = 200$$

Các yêu cầu phương pháp học cốt lõi:

- resampling ở cấp user;
- giữ toàn bộ observations của user được chọn;
- dùng cùng user sample cho tất cả K;
- tính paired differences trong từng bootstrap replicate.

Bootstrap chủ yếu được sử dụng để ước lượng uncertainty, thay vì tạo ra một lượng lớn hypothesis tests độc lập.

---

45. So sánh theo cặp

Vì mọi K được đánh giá trên cùng decision points, các so sánh history budget là **paired**.

Ví dụ:

$$\Delta\mathrm{AUC}(10, \mathrm{Full}) = \mathrm{AUC}(10) - \mathrm{AUC}(\mathrm{Full})$$

Chênh lệch được tính trong từng bootstrap replicate.

Báo cáo chính tập trung vào:

- point estimate;
- confidence interval;
- paired AUC difference;
- retention confidence interval.

Dự án không phụ thuộc vào việc thực hiện một hypothesis test riêng cho mọi cặp K.

Điều này tránh biến nghiên cứu thành một hệ thống multiple-comparison quá lớn.

---

46. Giả thuyết

H1 — Behavioral history có giá trị dự đoán

Tồn tại ít nhất một $K > 0$ sao cho:

$$\mathrm{AUC}(K) > \mathrm{AUC}(0)$$

H2 — Lợi ích của lịch sử bổ sung có xu hướng giảm

Lợi ích biên của việc bổ sung lịch sử có xu hướng giảm khi K tăng.

Không giả định tính đơn điệu tuyệt đối.

H3 — Bão hòa sớm

Một history budget tương đối nhỏ có thể duy trì phần lớn hiệu năng của Full condition.

Giả thuyết này có thể bị bác bỏ bởi kết quả.

H4 — History efficiency không đồng nhất

Lượng lịch sử cần thiết để đạt hiệu năng cao có thể khác nhau giữa các nhóm user theo mức độ hoạt động.

---

47. Sensitivity Analysis

Sensitivity analyses là phân tích phụ và **không được phép định nghĩa lại kết quả chính**.

47.1. History Window

Đánh giá một số giá trị W khác.

W chính được lựa chọn bằng development data và khóa trước final evaluation.

47.2. Session-Aware History

So sánh history chính không sessionized với các ngưỡng session-gap đã định trước:

- 15 phút;
- 30 phút;
- 60 phút.

47.3. History Aggregation

So sánh:

- mean pooling;
- recency-weighted pooling.

47.4. Lightweight Sequential Architecture

Nếu đủ khả năng tính toán, đánh giá một sequential encoder nhẹ như GRU.

Mục đích là kiểm tra liệu quan hệ:

$$K \rightarrow \mathrm{AUC}(K)$$

có phụ thuộc mạnh vào aggregation mechanism chính hay không.

47.5. Outcome khác

Đánh giá thêm:

- click;
- like.

ngoài outcome chính là long-view.

47.6. Temporal Stability

Chia experimental period thành các bin thời gian:

$$T_1, T_2, \ldots, T_m$$

và ước lượng:

$$\mathrm{AUC}(K, T_j)$$

Điều này kiểm tra liệu history-efficiency curve có ổn định theo thời gian hay không.

47.7. User Heterogeneity

Nhóm user theo mức độ hoạt động lịch sử và ước lượng:

$$\mathrm{AUC}_g(K)$$

Điều này kiểm tra liệu history requirement thực tế có khác nhau giữa user ít hoạt động và user hoạt động nhiều hay không.

---

48. History Efficiency theo User

Kết quả chính là kết quả toàn cục.

Phân tích phụ kiểm tra liệu history efficiency có thay đổi giữa các user hay không.

Với nhóm hoạt động g:

$$\mathrm{AUC}_g(K)$$

được ước lượng.

Có thể tính saturation point mô tả theo nhóm:

$$K_g^*$$

Dự án không giả định một history budget duy nhất hiệu quả như nhau với mọi user.

Tuy nhiên, subgroup analysis không thay thế đường cong global:

$$K \to \mathrm{AUC}(K)$$

Các subgroup được xem là phân tích phụ và không được dùng để thay đổi protocol chính.

---

49. Ổn định theo thời gian

Experimental period có thể được chia thành các đoạn thời gian đã định trước.

Với mỗi đoạn:

$$\mathrm{AUC}(K, T_j)$$

được tính toán.

Mục tiêu là kiểm tra:

$$K \to \mathrm{AUC}(K)$$

có ổn định theo thời gian hay không.

Nếu đường cong thay đổi theo thời gian, đó được báo cáo như một kết quả thực nghiệm chứ không coi là thất bại của nghiên cứu.

---

50. Khả thi về mặt tính toán

Dự án chủ động tránh việc sử dụng timeline vô hạn của user.

Ràng buộc tính toán chính là:

$$W + L_{\max}$$

History được tái dựng bằng indexing theo user và thứ tự thời gian.

Implementation không nên tái dựng toàn bộ history riêng biệt cho từng K.

Thay vào đó, với mỗi decision point, xây dựng:

$$H_t^{(\mathrm{Full})}$$

một lần rồi tạo:

$$H_t^{(K)} = \mathrm{Last}_K\left(H_t^{(\mathrm{Full})}\right)$$

cho từng K hữu hạn.

Điều này giảm preprocessing dư thừa.

Chi phí tính toán của từng K có thể được báo cáo riêng, nhưng không phải câu hỏi nghiên cứu chính.

---

51. Quy trình phát triển

Giai đoạn 1 — Data EDA

Kiểm tra:

- bảng/file có sẵn;
- khoảng thời gian;
- user ID;
- item ID;
- feedback fields;
- random-intervention indicators;
- missing values;
- event ordering.

Giai đoạn 2 — Data Contract

Khóa:

- định nghĩa eligible-history event;
- định nghĩa evaluation event;
- feature-availability rules;
- candidate representation;
- target definition.

Giai đoạn 3 — Xây dựng Decision Points

Xây dựng:

$$D_{\text{eval}}$$

Kiểm tra mỗi evaluation unit có:

- user;
- timestamp;
- observed candidate;
- target.

Giai đoạn 4 — Tái dựng History

Xây dựng:

$$H_t^W$$

và kiểm tra thứ tự thời gian nghiêm ngặt.

Giai đoạn 5 — Chọn W, $L_{\max}$

Sử dụng KuaiRand-1K development data.

Giai đoạn 6 — Leakage Tests

Kiểm tra toàn bộ information-availability invariants.

Giai đoạn 7 — Sinh các mức K

$$K \in \{0, 1, 5, 10, 20, 50, 100, \text{Full}\}$$

Giai đoạn 8 — Baselines

Triển khai:

- popularity;
- video-only;
- history-only diagnostic.

Giai đoạn 9 — Core Models

Train từng M_K độc lập.

Giai đoạn 10 — Freeze

Freeze toàn bộ model parameters.

Giai đoạn 11 — Final Evaluation

Đánh giá mọi M_K trên cùng:

$$D_{\text{eval}}$$

Giai đoạn 12 — Bootstrap

Thực hiện user-level paired bootstrap.

Giai đoạn 13 — Primary Analysis

Sinh:

- AUC(K);
- PR-AUC(K);
- ΔAUC;
- Retention(K);
- confidence intervals;
- K^*.

Giai đoạn 14 — Secondary Analysis

Thực hiện các sensitivity analyses đã định trước.

---

52. Protocol Lock

Trước khi đánh giá cuối trên KuaiRand-27K, các yếu tố sau được khóa:

- exact dataset files;
- temporal boundaries;
- eligible-history event definition;
- evaluation-event definition;
- target;
- candidate representation;
- user representation;
- W;
- $L_{\max}$;
- các giá trị K;
- history aggregation;
- architecture;
- parameter count;
- optimizer;
- learning rate;
- batch size;
- training procedure;
- validation split;
- early-stopping rule;
- random seeds;
- missing-history handling;
- evaluation-set construction;
- primary metric;
- retention formula;
- retention stability rule;
- saturation threshold;
- bootstrap procedure;
- bootstrap replicate count;
- primary reporting procedure.

Sau khi protocol được khóa, các lựa chọn này **không được thay đổi chỉ vì kết quả final không thuận lợi**.

Kết quả bất ngờ vẫn được coi là kết quả nghiên cứu hợp lệ.

53. Yêu cầu về khả năng tái lập

Thí nghiệm cuối ghi nhận:

- exact dataset release;
- exact raw input files;
- checksums nếu phù hợp;
- timestamp boundaries;
- eligible-history tables/files;
- evaluation-event definition;
- W;
- $L_{\max}$;
- tất cả K;
- feature definitions;
- feature availability rules;
- architecture;
- parameter count;
- optimizer;
- learning rate;
- batch size;
- random seeds;
- early-stopping configuration;
- training epochs;
- validation protocol;
- bootstrap method;
- bootstrap replicate count;
- evaluation event identifiers;
- preprocessing version;
- code version/commit.

Mọi lựa chọn có thể ảnh hưởng tới kết quả chính phải có khả năng được tái dựng từ configuration và code.

---

54. Invariant thực nghiệm cốt lõi

Thí nghiệm chính được kiểm soát bởi:

$$\text{Dataset} = \text{Constant}$$

$$\text{Evaluation Units} = \text{Constant}$$

$$\text{Observed Candidates} = \text{Constant}$$

$$\text{Target} = \text{Constant}$$

$$\text{Candidate Representation} = \text{Constant}$$

$$\text{Architecture} = \text{Constant}$$

$$\text{Parameter Count} = \text{Constant}$$

$$\text{Training Protocol} = \text{Constant}$$

$$\text{Evaluation Period} = \text{Constant}$$

$$\text{History Eligibility Rules} = \text{Constant}$$

$$\text{History Window} = \text{Constant}$$

Chỉ có:

$$\boxed{\text{Behavioral History Budget } K = \text{Variable}}$$

Do đó:

K là biến can thiệp chính của thí nghiệm.

---

55. Kết quả chính

Kết quả chính không phải là một con số AUC duy nhất.

Kết quả trung tâm là quan hệ thực nghiệm:

$$K \rightarrow \text{AUC}(K)$$

Kết quả trung tâm thứ hai là:

$$K \rightarrow \text{Retention}(K)$$

Bảng kết quả chính:

History Budget	ROC-AUC	PR-AUC	ΔAUC vs Full	Retention	95% CI
0	—	—	—	—	—
1	—	—	—	—	—
5	—	—	—	—	—

History Budget	ROC-AUC	PR-AUC	ΔAUC vs Full	Retention	95% CI
10	—	—	—	—	—
20	—	—	—	—	—
50	—	—	—	—	—
100	—	—	—	—	—
Full	—	—	0	100%*	—

* Khi mẫu số của retention hợp lệ.

Các visualization chính:

1. ROC-AUC theo history budget;
2. Relative retention theo history budget;
3. confidence/uncertainty intervals;
4. tùy chọn: sequence-length distribution và computational cost.

Trục x có thể hiển thị theo logarithmic scale để dễ quan sát, nhưng các giá trị K thực tế vẫn chính xác là các điều kiện được định trước.

---

56. Các dạng kết quả có thể xảy ra

Dự án **không giả định trước kết quả số cụ thể**.

Trường hợp A — Bão hòa sớm

$$\mathrm{AUC}(10) \approx \mathrm{AUC}(\mathrm{Full})$$

Điều này hỗ trợ giả thuyết rằng một lượng nhỏ history gần đây đã chứa phần lớn tín hiệu dự đoán mà mô hình có thể khai thác.

Trường hợp B — Cải thiện dần

$$\mathrm{AUC}(1) < \mathrm{AUC}(5) < \cdots < \mathrm{AUC}(\mathrm{Full})$$

Điều này cho thấy history bổ sung tiếp tục mang lại tín hiệu dự đoán hữu ích.

Trường hợp C — Quan hệ không đơn điệu

Ví dụ:

$$\mathrm{AUC}(10) > \mathrm{AUC}(20)$$

Có thể phản ánh:

- redundancy;
- preference mixing;
- tương tác lịch sử nhiễu;
- optimization variation.

Không đơn điệu **không làm mất giá trị của câu hỏi nghiên cứu**.

Trường hợp D — Tác động history yếu

$$\mathrm{AUC}(0) \approx \mathrm{AUC}(\mathrm{Full})$$

Kết luận phù hợp là:

> Trong candidate representation và observed-exposure evaluation protocol được xác định, behavioral history cung cấp rất ít predictive discrimination bổ sung so với thông tin từ candidate video.

Không được kết luận rằng behavioral history nói chung là vô dụng.

---

57. Diễn giải $K = 0$

$K = 0$ được diễn giải là:

> **Video-only learned baseline.**

Nếu:

$$\mathrm{AUC}(0) \approx \mathrm{AUC}(\mathrm{Full})$$

dự án không kết luận:

> Behavioral history vô dụng.

Mà chỉ kết luận:

> Trong candidate representation và observed-exposure evaluation protocol đã định nghĩa, việc bổ sung behavioral history tạo ra rất ít predictive discrimination bổ sung ngoài thông tin từ candidate video.

History-only diagnostic giúp xác định liệu behavioral history có chứa tín hiệu dự đoán không được candidate representation nắm bắt hay không.

---

58. Full History không phải Oracle

Full condition chỉ đơn giản là:

> tất cả eligible events trong W, giới hạn bởi $L_{\max}$.

Nó không phải:

- oracle;
- complete user knowledge;
- history tối ưu về lý thuyết;
- hiệu năng tối đa có thể đạt;
- production recommender.

Diễn giải luôn mang tính tương đối:

> **Full là reference condition được lựa chọn bởi protocol thực nghiệm này.**

Do đó, "95% retention" nghĩa là 95% hiệu năng dự đoán vượt trên random của **Full condition đo được**, chứ không phải 95% hiệu năng gợi ý tối đa về mặt lý thuyết.

---

59. Đóng góp chính

Dự án không tuyên bố giới thiệu một recommendation algorithm mới.

Đóng góp chính là một framework thực nghiệm để đo:

$$\text{Behavioral History Budget} \rightarrow \text{Predictive Recommendation Performance}$$

Thay vì hỏi:

> Kiến trúc recommendation nào tốt nhất?

dự án hỏi:

> **Một hệ thống gợi ý cần bao nhiêu lịch sử hành vi gần đây để đạt được phần lớn hiệu năng dự đoán đo được?**

Điều này chuyển trọng tâm phân tích recommendation offline sang:

> **Behavioral-History Efficiency — Hiệu quả của lịch sử hành vi.**

---

60. Phạm vi của các kết luận

Mọi kết luận chỉ được giới hạn trong:

- phiên bản/file KuaiRand cụ thể được sử dụng;
- temporal protocol được định nghĩa;
- history window W;
- maximum sequence length $L_{\max}$;
- model architecture;
- candidate representation;
- target;
- observed-intervention evaluation population.

Ví dụ, nếu:

$$\mathrm{Retention}(10) = 0.95$$

kết luận hợp lệ là:

> Trong môi trường thực nghiệm KuaiRand được định nghĩa trước, điều kiện $K = 10$ đạt khoảng 95% hiệu năng dự đoán vượt trên mức ngẫu nhiên của Full-history model.

Dự án **không kết luận**:

> Một hệ thống short-video recommendation thực tế chỉ cần 10 tương tác.

Cũng không kết luận:

> 10 tương tác chứa 95% thông tin của người dùng.

---

61. Những điều dự án không tuyên bố

Dự án không nhằm:

- tái tạo production recommender của Kuaishou;
- tái dựng đầy đủ recommendation slate lịch sử;
- ước lượng outcome của mọi candidate không quan sát được;
- thực hiện causal treatment-effect estimation;
- tuyên bố random intervention loại bỏ mọi nguồn observational bias;
- tuyên bố một history length tối ưu mang tính phổ quát;
- đồng nhất history length với lượng thông tin theo lý thuyết thông tin;
- coi Full history là oracle;
- diễn giải AUC là chất lượng hoàn chỉnh của recommendation policy;
- tối ưu computational efficiency như câu hỏi nghiên cứu chính;
- giới thiệu recommendation architecture mới;
- chứng minh một K duy nhất phù hợp với mọi user;

- chứng minh một K duy nhất phù hợp với mọi platform;
- suy ra trực tiếp yêu cầu của production system từ kết quả offline.

---

62. Các mối đe dọa đối với validity và biện pháp giảm thiểu

Threat 1 — History của user quá dài

User hoạt động mạnh có thể có timeline rất dài.

Mitigation:

Sử dụng temporal window W và maximum sequence length $L_{\max}$ được lựa chọn bằng development data.

Threat 2 — Temporal leakage

Future behavior có thể vô tình đi vào history hoặc dynamic feature.

Mitigation:

Lọc timestamp nghiêm ngặt:

$$t_i < t$$

Mọi dynamic feature được tái dựng chỉ bằng thông tin có trước decision timestamp.

Threat 3 — Candidate không đầy đủ

Historical candidate slate hoàn chỉnh không có sẵn.

Mitigation:

Chỉ đánh giá observed intervention exposures và tránh các policy/counterfactual claims.

Threat 4 — Phụ thuộc giữa các observation của cùng user

Một user có thể đóng góp nhiều observations.

Mitigation:

User-level clustered bootstrap.

Threat 5 — Retention không ổn định

Full-history AUC có thể gần 0.5.

Mitigation:

Sử dụng predefined denominator-stability rule và báo cáo absolute AUC differences khi retention không ổn định.

Threat 6 — Phụ thuộc vào architecture

Một aggregation architecture cụ thể có thể tạo ra history-performance curve cụ thể.

Mitigation:

Primary architecture nhẹ, fixed-capacity và sensitivity analysis với architecture tuần tự.

Threat 7 — Lựa chọn W và $L_{\max}$

Các history window và sequence limit khác nhau có thể tạo Full reference khác nhau.

Mitigation:

Chọn $W, L_{\max}$ trên development data, khóa trước final testing và thực hiện W-sensitivity analysis.

Threat 8 — Training/inference mismatch

Full-trained model có thể hoạt động khác khi history bị cắt lúc inference.

Mitigation:

Budget-matched training là protocol chính. Full-trained truncation là thí nghiệm phụ.

Threat 9 — Model performance không đơn điệu

K lớn hơn đôi khi có thể kém hơn K nhỏ hơn.

Mitigation:

Không giả định monotonicity. Báo cáo paired bootstrap uncertainty và toàn bộ đường cong:

$$K \to \mathrm{AUC}(K)$$

Threat 10 — Kết luận phụ thuộc dataset

Kết quả có thể không generalize sang platform hoặc domain khác.

Mitigation:

Tất cả claims bị giới hạn rõ ràng trong KuaiRand experimental environment.

Generalization được để dành cho nghiên cứu tương lai.

---

63. Kiến trúc phần mềm

Implementation chia thành ba tầng.

Data Layer

Chịu trách nhiệm:

- raw data ingestion;
- chronological ordering;
- train/validation/evaluation partitioning;
- eligible-history construction;
- decision-point construction;
- history-window construction;
- K-based history generation;
- feature-availability checks;
- leakage tests.

Model Layer

Chịu trách nhiệm:

- event encoding;
- history aggregation;
- user-state construction;
- candidate representation;
- engagement prediction;
- training;
- parameter freezing;
- inference.

Evaluation Layer

Chịu trách nhiệm:

- fixed evaluation set;
- ROC-AUC;
- PR-AUC;
- paired AUC differences;
- user-level bootstrap;
- confidence intervals;
- retention;
- saturation analysis;
- subgroup analysis;
- temporal analysis;
- sensitivity analysis;

- visualization.

---

64. Thứ tự implementation

Implementation **không bắt đầu bằng model optimization**.

Thứ tự bắt buộc:

$$\text{EDA}$$

$$\downarrow$$

$$\text{Data Contract}$$

$$\downarrow$$

$$\text{Temporal Split}$$

$$\downarrow$$

$$\text{Eligible Event Definition}$$

$$\downarrow$$

$$\text{Decision-Point Construction}$$

$$\downarrow$$

$$\text{History Reconstruction}$$

$$\downarrow$$

$$\text{Leakage Tests}$$

$$\downarrow$$

$$\text{Fixed Evaluation Set}$$

$$\downarrow$$

$$W/L_{\max}\ \text{Selection}$$

$$\downarrow$$

$$\text{Protocol Lock}$$

$$\downarrow$$

$$\text{K Generation}$$

$$\downarrow$$

$$\text{Baselines}$$

$$\downarrow$$

$$\text{Core Models}$$

$$\downarrow$$

$$\text{Frozen Evaluation}$$

$$\downarrow$$

$$\text{Bootstrap}$$

$$\downarrow$$

$$\text{Primary Analysis}$$

$$\downarrow$$

$$\text{Sensitivity Analysis}$$

Milestone đầu tiên **không phải**:

> Train một recommender tốt.

Mà là:

> **Xây dựng được cùng một decision point và pre-decision history hợp lệ cho mọi K, hoàn toàn không leakage.**

---

65. Logic thực nghiệm cuối cùng

Logic khoa học hoàn chỉnh:

$$\boxed{\text{Behavioral History Budget } K}$$

$$\downarrow$$

$$\text{Fixed Model Specification}$$

$$\downarrow$$

$$\text{Frozen Trained Model}$$

$$\downarrow$$

$$\text{Observed Candidate}$$

$$\downarrow$$

$$\text{Prediction Score}$$

$$\downarrow$$

$$\text{AUC}$$

Sau đó so sánh:

$$\text{AUC}(K) \qquad \text{với} \qquad \text{AUC}(\text{Full})$$

để tính:

$$\text{Retention}(K)$$

và xác định:

$$K^*$$

Can thiệp thực nghiệm duy nhất là:

$$\boxed{\text{lượng lịch sử hành vi gần đây được cung cấp cho mô hình}}$$

Các thành phần chính khác của thí nghiệm được giữ cố định.

---

66. Phát biểu nghiên cứu chính

Dự án nghiên cứu liệu hiệu năng dự đoán của một hệ thống gợi ý video ngắn có phụ thuộc mạnh vào lịch sử hành vi dài hay không, hay một lượng tương đối nhỏ các tương tác gần đây đã đủ để chứa phần lớn tín hiệu dự đoán có thể đo được.

Nghiên cứu xem lịch sử hành vi như một **ngân sách thực nghiệm có thể kiểm soát**. Mỗi evaluation example là một sự kiện hiển thị intervention quan sát được và cố định. History của người dùng được tái dựng nghiêm ngặt trước timestamp hiển thị. Full history được giới hạn bởi một temporal window và maximum sequence length được xác định trước. Các history budget hữu hạn là các tập con lồng nhau của Full reference.

Mỗi budget được train độc lập với cùng model specification. Tất cả model được freeze trước khi đánh giá trong experimental period. Mọi budget được đánh giá trên cùng các observed exposure events, cùng candidate và cùng target. User-level clustered bootstrap được sử dụng để ước lượng uncertainty và bảo toàn repeated observations từ cùng user.

Hai output chính là:

$$K \to \mathrm{AUC}(K)$$

và:

$$K \to \mathrm{Retention}(K)$$

Điểm bão hòa mô tả là:

$$K^*$$

Do đó, câu hỏi trung tâm là:

> **Một hệ thống gợi ý cần ít đến mức nào về lịch sử hành vi gần đây nhưng vẫn duy trì được phần lớn hiệu năng dự đoán đo được?**

Đóng góp dự kiến không phải một recommendation architecture mới, mà là một phép đo thực nghiệm có kiểm soát về:

> **Behavioral-History Efficiency — hiệu quả của lịch sử hành vi**

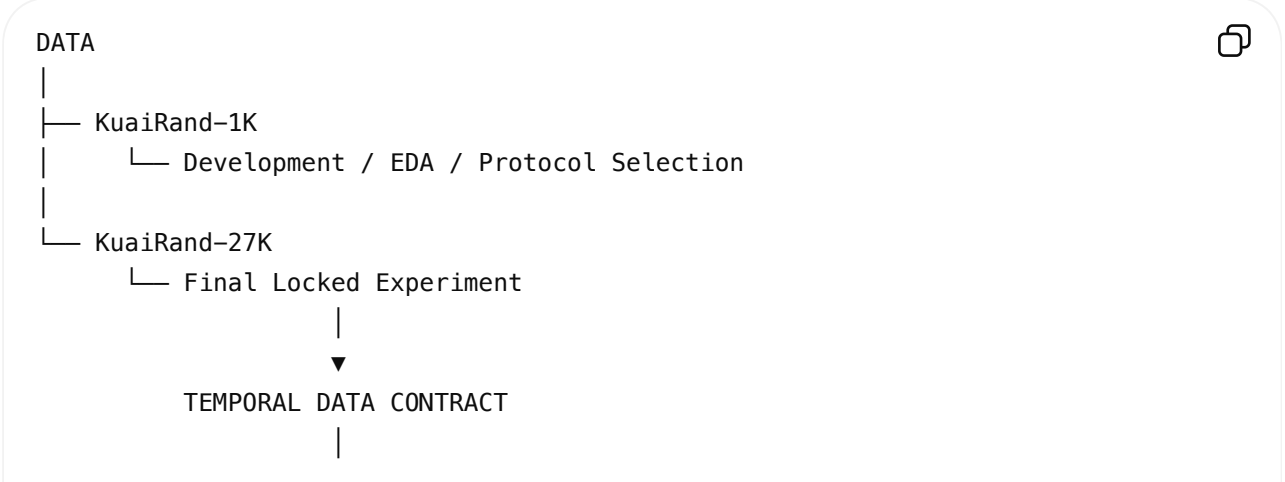
trong một môi trường đánh giá offline được định nghĩa rõ ràng.

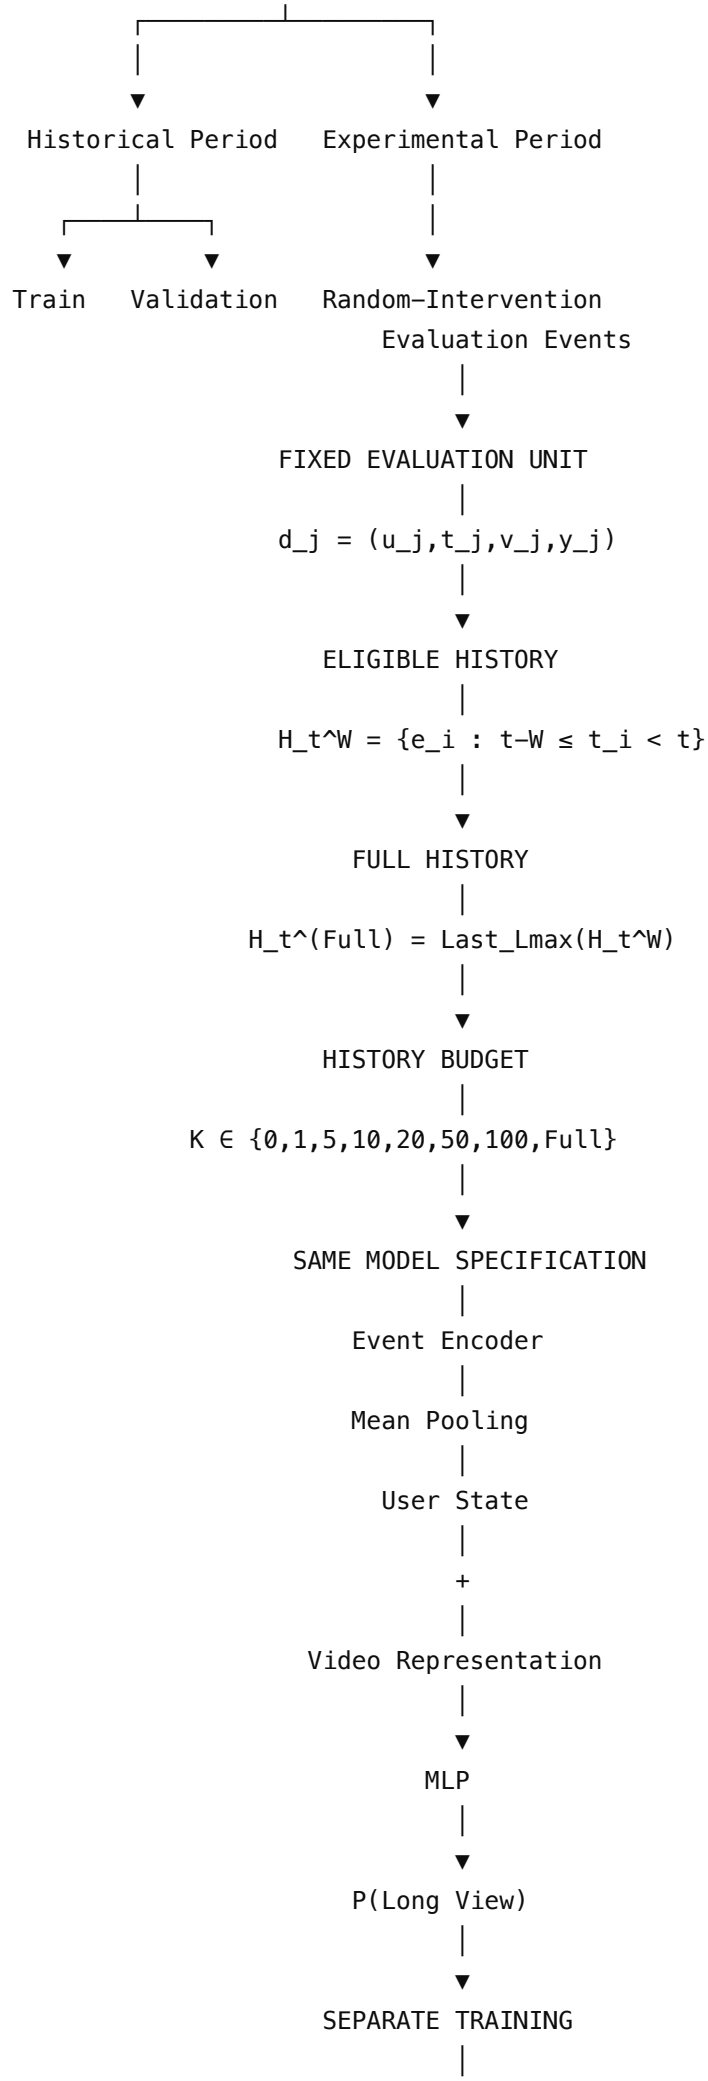
---

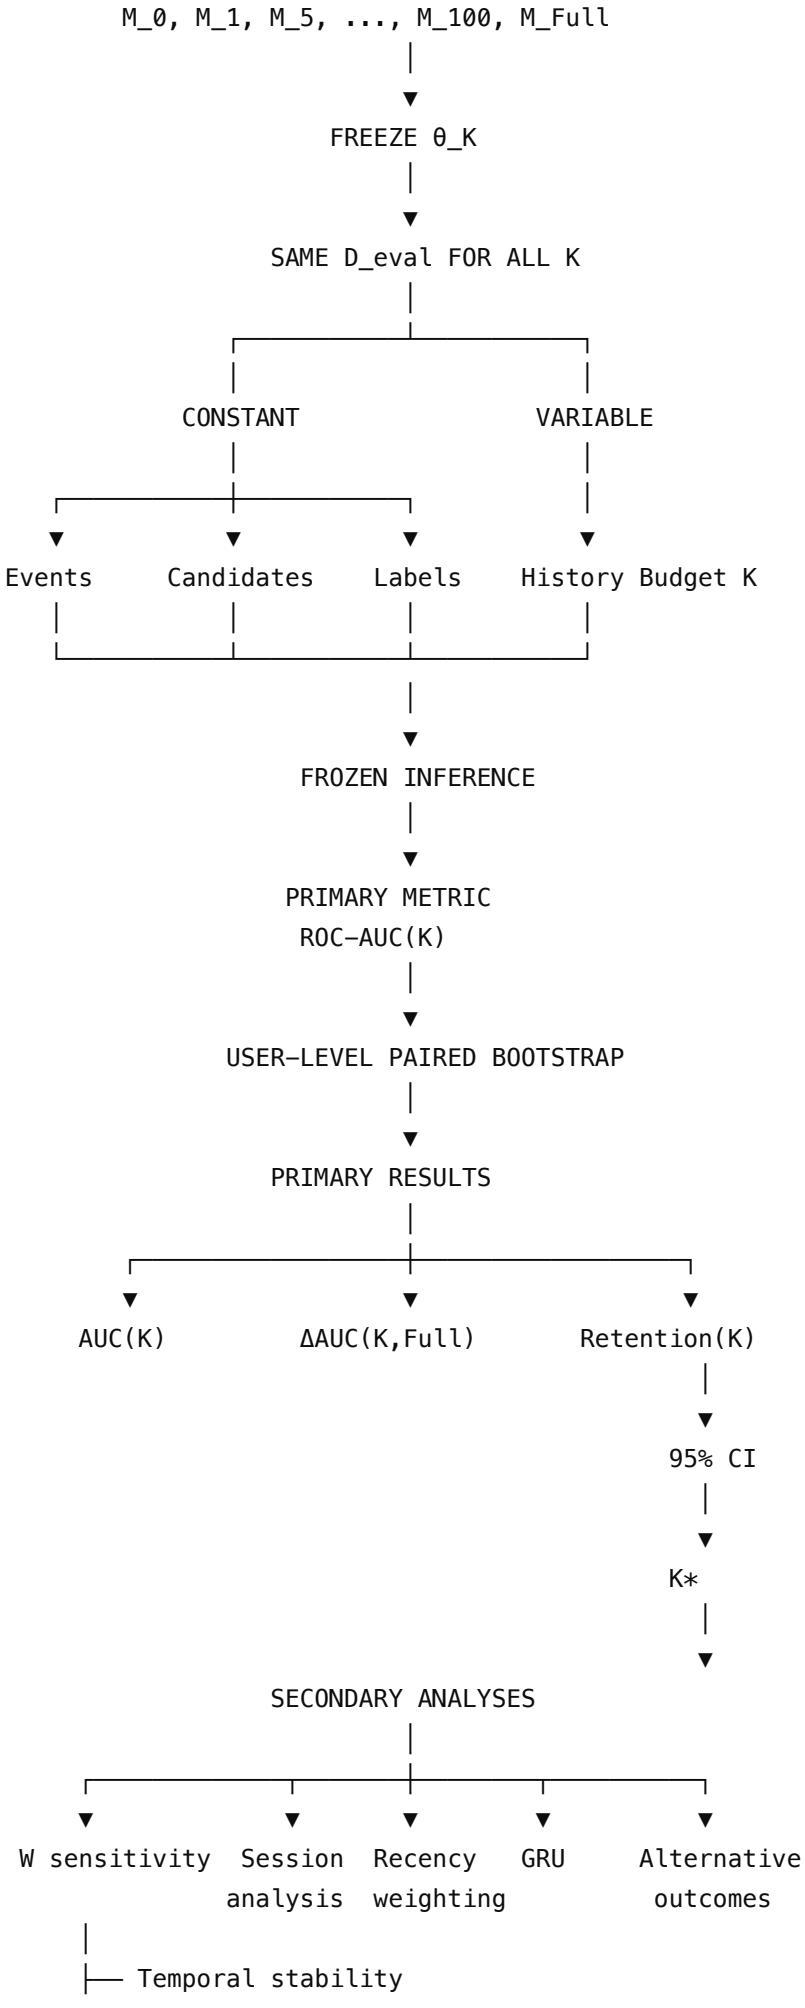
67. Tóm tắt trong một câu

> **Giảm lượng lịch sử hành vi, giữ nguyên dataset, decision points, observed candidates, target, feature representation, model capacity, training protocol và evaluation procedure, sau đó đo xem bao nhiêu hiệu năng dự đoán của hệ thống gợi ý vẫn được duy trì.**

FINAL PROTOCOL — TOÀN BỘ TRONG MỘT SƠ ĐỒ




Historical Period
Experimental Period
Train
Validation
Random-Intervention
Evaluation Events
FIXED EVALUATION UNIT
d_j = (u_j,t_j,v_j,y_j)
ELIGIBLE HISTORY
H_t^W = {e_i : t−W ≤ t_i < t}
FULL HISTORY
H_t^(Full) = Last_Lmax(H_t^W)
HISTORY BUDGET
K ∈ {0,1,5,10,20,50,100,Full}
SAME MODEL SPECIFICATION
Event Encoder
Mean Pooling
User State
+
Video Representation
MLP
P(Long View)
SEPARATE TRAINING


M_0, M_1, M_5, ..., M_100, M_Full
FREEZE θ_K
SAME D_eval FOR ALL K
CONSTANT
VARIABLE
Events
Candidates
Labels
History Budget K
FROZEN INFERENCE
PRIMARY METRIC
ROC-AUC(K)
USER-LEVEL PAIRED BOOTSTRAP
PRIMARY RESULTS
AUC(K)
ΔAUC(K,Full)
Retention(K)
95% CI
K*
SECONDARY ANALYSES
W sensitivity
Session analysis
Recency weighting
GRU
Alternative outcomes
Temporal stability

```
├── User-activity heterogeneity
└── Full-trained truncation
```

Công thức cốt lõi của toàn bộ nghiên cứu

$$\boxed{H_t^W = \{e_i : t - W \le t_i < t\}}$$

$$\boxed{H_t^{(K)} = \mathrm{Last}_{\min(K, L_{\max})}(H_t^W)}$$

$$\boxed{H_t^{(\mathrm{Full})} = \mathrm{Last}_{L_{\max}}(H_t^W)}$$

$$\boxed{\hat{p}_t^{(K)} = P(Y = 1 \mid H_t^{(K)}, V_t)}$$

$$\boxed{\mathrm{Retention}(K) = \frac{\mathrm{AUC}(K) - 0.5}{\mathrm{AUC}(\mathrm{Full}) - 0.5}}$$

$$\boxed{K^* = \min\{K : \mathrm{Retention}(K) \ge 0.95\}}$$

Và toàn bộ proposal quy về một nguyên tắc duy nhất:

$$\boxed{\text{Everything is fixed except the behavioral history budget } K.}$$

ChatGPT có thể mắc lỗi. Hãy kiểm tra các thông tin quan trọng.